

Evidential MIMO 채널 예측에서 부분 파라미터 업데이트를 이용한 OOD 적응 분석

Parameter-Efficient OOD Adaptation in Evidential MIMO Channel Prediction

이유빈¹, 이강원² \ ¹ 세종대학교 지능기전공학부 스마트기기전공 학부생, ² 세종대학교 컴퓨터공학과 교수 \ 22011969@sju.ac.kr, kangwon.lee@sejong.ac.kr

요약

Evidential MIMO 채널 예측기가 학습하지 않은 채널 환경을 만나면 추가 적응이 필요할 수 있지만, predictor 전체를 Fine-Tuning 하면 계산 비용과 GPU memory 가 증가한다. 본 연구는 UACP(Uncertainty-Aware Channel Prediction) 기반 predictor 를 Small, Medium, Full 세 update scope 로 나누고, 80 ns ID-Hard 조건의 normalized beamforming gain 을 회복하는 최소 범위를 비교하였다. 평가 대상은 160, 180, 200 ns OOD delay spread 와 세 독립 seed 의 9 개 조건이다. Medium 은 마지막 네 residual block 과 evidential heads 를 업데이트하며 1,480,728 개, 전체의 12.5323% parameter 를 학습한다. 모든 9 개 조건에서 Medium 이 ID-Hard 수준의 normalized beamforming gain 을 회복하는 minimum evaluated sufficient scope 로 나타났다. Medium 은 Full 보다 trainable parameter 87.47%, measured training time 45.92%, peak VRAM 72.57%를 줄였다. Pre-adaptation Epistemic severity 는 160 ns 에서 200 ns 로 갈수록 증가했지만 required scope 는 모두 Medium 이었다. 따라서 평가한 조건에서는 Partial Fine-Tuning 의 비용 절감 가능성을 확인했지만, uncertainty magnitude 만으로 필요한 adaptation budget 을 결정하는 관계는 확인하지 못했다.

주제어: MIMO, Channel State Information, Evidential Regression, Out-of-Distribution, Partial Fine-Tuning, Beamforming

1. 서론

Multiple-Input Multiple-Output(MIMO)은 여러 송·수신 안테나를 사용하여 무선 채널의 공간적 자유도를 활용하는 기술이다. 송신기가 여러 안테나에서 신호를 어떤 방향으로 전송할지 결정하려면 Channel State Information(CSI)이 필요하다. OFDM에서는 여러 주파수 구간인 subcarrier 를 사용하므로, 각 subcarrier 의 주파수 응답을 나타내는 Channel Frequency Response(CFR)를 정확히 예측하는 것이 중요하다. 모든 CFR 을 feedback 하면 전송 overhead 가 커지기 때문에 일부 관측으로 전체 CFR 을 복원하는 연구가 진행되어 왔다. CsiNet 계열 연구는 낮은 feedback overhead 에서 CSI 를 복원하고 beamforming 품질을 유지하는 방법을 제시하였다[1].

UACP 는 sparse CFR observation 에서 full CFR 을 복원하는 predictor 이며, Evidential Regression 을 이용해 예측과 uncertainty 를 함께 출력한다. Aleatoric uncertainty 는 데이터 자체의 변동성에서 비롯되고, Epistemic uncertainty 는 모델이 충분히 경험하지 못한 입력에서 증가할 수 있는 model uncertainty 이다[2]. 원 UACP 연구는 Epistemic uncertainty 를 이용해 학습 분포에서 벗어난 channel regime 을 감지하고 feedback/adaptation 동작을 조절하는 구조를 다룬다[3]. Dataset shift 에서는 예측 성능과 uncertainty 를 별도로 평가해야 한다는 점도 보고되었다[4].

OOD(Out-of-Distribution) channel 을 감지한 뒤 adaptation 이 필요하다는 사실은 predictor 전체를 업데이트해야 한다는 뜻과 다르다. Full Fine-Tuning 은 모든 parameter 와 optimizer state 를 관리하므로 비용이 증가할 수 있다. Adapter 와 LoRA 는 전체 pretrained

parameter 를 업데이트하지 않는 Parameter-Efficient Fine-Tuning(PEFT)의 대표적인 연구 방향이다[5,6]. 본 연구는 Adapter 나 LoRA 를 구현하지 않고, UACP predictor 에서 업데이트하는 residual block 범위를 제한하는 Partial Fine-Tuning 을 분석한다.

본 연구는 세 질문에 답한다. 첫째, OOD channel 에서 일부 parameter 만 업데이트해도 ID-Hard 수준의 beamforming-oriented CSI quality 를 회복할 수 있는가? 둘째, 가능한 경우 Full Fine-Tuning 보다 parameter, time, memory 를 얼마나 줄일 수 있는가? 셋째, Fine-Tuning 전 Epistemic severity 가 필요한 update scope 를 결정하는 단서가 되는가? 이를 위해 동일 pretrained checkpoint 와 paired clean CFR 조건에서 Small, Medium, Full 을 비교하였다.

본 연구의 기여는 다음과 같다. (1) 160–200 ns OOD 에서 normalized BF criterion 으로 minimum evaluated update scope 를 정의하였다. (2) Medium 과 Full 의 parameter, training time, peak VRAM 을 비교하였다. (3) pre-adaptation Epistemic severity 와 required scope 의 관계를 분석하여 uncertainty magnitude 와 adaptation budget 이 같은 개념인지 검토하였다.

2. 실험 디자인

2.1 UACP 채널 예측 모델과 OOD adaptation

Predictor 의 입력은 일부 subcarrier 의 sparse CFR 과 어떤 위치가 관측되었는지를 나타내는 mask 이다. 입력은 feature extraction 과 32 개의 residual block 을 거쳐 CFR mean 과 evidential parameters 를 출력한다. Residual block 은 변환된 특징을 원래 입력 특징에 더하는 구조로, 깊은 network 에서 특징을 단계적으로 학습하도록 돕는다. Prediction head 는 backbone 특징을 이용해 최종 CFR 과 uncertainty 관련 값을 출력한다. 현재 구현의 evidential output 은 CFR mean γ 와 uncertainty 계산에 사용되는 Ψ, κ, ν 이다. 따라서 CFR prediction 과 uncertainty 는 서로 다른 모델이 아니라 같은 predictor 의 출력에서 계산된다.

원 UACP 논문은 MIMO-OFDM, evidential regression, uncertainty 기반 feedback/adaptation 을 설명하지만, 아래의 Partial Fine-Tuning layer 범위와 adaptation dataset 구성까지 공개한 것은 아니다. 그러므로 논문에 직접 명시되지 않은 현재 구현 항목은 `IMPLEMENTATION-ASSUMPTION`으로 표시한다.



Figure 1. Sparse CFR 과 mask 가 predictor 에 입력되고 CFR 및 evidential output 으로 이어지는 흐름이다. 색으로 구분한 scope 는 마지막 block 과 head 만 업데이트하는 Small, 마지막 네 block 과 head 를 업데이트하는 Medium, 전체를 업데이트하는 Full 의 차이를 나타낸다.

2.2 데이터 및 학습 설정

원래 training distribution 은 RMS delay spread 10–100 ns 이다. 80 ns 는 학습 범위 안에서 상대적으로 어려운 ID-Hard reference 이고, 160/180/200 ns 는 100 ns 를 넘으므로 OOD adaptation 대상이다. 모든 scope 는 같은 clean CFR, sample order, mask/noise schedule 을 사용하였다.

항목	설정
MIMO / subcarrier	$2 \times 2 / K=1024$
Training / adaptation	10–100 ns / 160, 180, 200 ns
Input / target	sparse CFR + mask / clean full CFR
Observation noise	reported CFR 에 15 dB complex AWGN
Ng / optimizer	{4, 8, 16, 32} balanced / Adam

LR / batch / epoch	1e-4 / 8 / 3
Precision / regularizer	FP32 / $\lambda_{\text{reg}}=1e-3$
Seeds	20260926, 20260927, 20260928

Sionna 2.0.1 과 TDL-A channel generation, zero mobility, `normalize=false`, 관측 noise pipeline 은 `IMPLEMENTATION-ASSUMPTION` 이다. Clean CFR 은 split 과 seed 별로 독립 생성되었고 train/validation/test 및 cross-seed hash overlap 은 0 이었다. 동일 seed 의 scope 간에는 같은 CFR 과 mask/noise schedule 을 공유하였다.

2.3 Partial Fine-Tuning 범위

Fine-Tuning 은 pretrained model parameter 를 새로운 OOD 데이터에 맞추어 추가 업데이트하는 과정이다. Partial Fine-Tuning 은 전체 parameter 가 아니라 선택한 layer 만 업데이트하는 방식이다. 본 연구의 scope 는 다음과 같다.

Scope	업데이트 layer	Trainable parameters	전체 대비
Small	ResidualBlock 31 + 4 evidential heads	373,656	3.1625%
Medium	ResidualBlock 28-31 + 4 evidential heads	1,480,728	12.5323%
Full	전체 predictor	11,815,320	100%

뒤쪽 residual block 과 head 를 업데이트하는 것은 현재 구현의 Partial FT 설계 선택이며 원 UACP 가 공식적으로 제시한 adaptation 범위는 아니다. Partial run 의 frozen parameter maximum difference 는 0 이었다.

2.4 Normalized Beamforming Gain 기반 성능 평가

NMSE 만으로는 channel error 가 실제 송신 방향 선택에 미치는 영향을 직접 알기 어렵다. 따라서 predicted CSI 로 선택한 beamforming 방향을 clean channel 에 적용했을 때의 gain 을 평가하는 communication-aware surrogate 를 사용하였다. 이는 BER/BLER, throughput, 실제 QoS 측정치 아니다.

각 subcarrier k 에서 clean channel 을 H_k , predicted channel 을 $\hat{H}_k$ 라 한다. 먼저 predicted channel 에서 신호가 가장 강하게 전달되는 송신 방향을 얻기 위해 SVD 를 사용하고, 그 principal right singular vector 를 $\hat{v}_k$ 로 둔다.

$$G_{\text{pred}}(k) = \| H_k \hat{v}_k \|^2$$

이는 predicted CSI 로 정한 방향을 실제 clean channel 에 적용했을 때의 gain 이다. Perfect CSI 를 알고 있을 때의 최대 gain 은 다음과 같다.

$$G_{\text{oraCle}}(k) = \sigma_{\max}(H_k)^2$$

따라서 normalized beamforming gain 은 다음과 같다.

$$G_{\text{BF}}(k) = G_{\text{pred}}(k) / G_{\text{oraCle}}(k)$$

값이 1 에 가까울수록 predicted CSI 가 clean channel 의 dominant spatial direction 을 잘 보존한다. Full-band gain 은 모든 subcarrier gain 의 평균이다. Sanity test 에서 perfect/oracle gain 은 1.0, random unit beamformer 평균은 0.541518 이었고 finite/range 검사를 통과하였다.

ID-Hard reference 는 Ng16 에서 0.994180, Ng32 에서 0.993673 이다. 동일 seed 에서 두 Ng 의 adaptation 후 평균 gain 이 모두 seed 별 ID-Hard reference 이상이면 pass 로 정의하고, Small→Medium→Full 순서에서 처음 pass 한 scope 를 minimum evaluated performance-sufficient scope 로 정의하였다.

2.5 Epistemic uncertainty 기반 OOD severity

이번 논문에서는 Fine-Tuning 전 Epistemic uncertainty 만 사용한다. Ng 마다 uncertainty 의 기본 scale 이 다르므로 raw uncertainty

를 직접 비교하지 않고 ID 데이터의 Ng 별 q99 threshold 와 비교한다. OOD sample 의 Epistemic uncertainty 를 U_{epi} , 해당 Ng 의 fixed ID q99 threshold 를 τ_{Ng} 라 하면 severity 는 다음과 같다.

$$z = \log_{10}(U_{\text{epi}} / \tau_{\text{Ng}})$$

$z=0$ 은 ID q99 와 같은 크기이고, $z>0$ 은 ID 기준보다 높은 uncertainty 이다. 예를 들어 $z=1$ 이면 threshold 의 10 배이다. 이 severity 와 2.4 에서 정의한 BF-only required scope 를 3.3 에서 비교한다.

3. 결과 분석

3.1 OOD 환경에서의 최소 Fine-Tuning 범위

2.4 의 ID-Hard BF criterion 을 사용해 세 scope 를 Small→Medium→Full 순서로 확인하였다. Raw 결과는 다음과 같다.

OOD delay	Small	Medium	Full	Minimum evaluated scope
160 ns	0/3	3/3	3/3	Medium
180 ns	0/3	3/3	2/3	Medium
200 ns	0/3	3/3	2/3	Medium

Small 은 특히 Ng32 에서 ID-Hard reference 보다 낮은 seed 가 반복되어 joint criterion 을 통과하지 못했다. Medium 은 모든 delay 의 세 seed 에서 Ng16 과 Ng32 reference 를 함께 넘었다. Full 이 180/200 ns 에서 항상 통과하지 않은 사실도 확인되지만, fixed 3-epoch protocol 에서의 관찰이며 원인은 본 실험에서 분석하지 않았다. 따라서 Partial FT 가 Full 보다 본질적으로 우수하거나 Full 이 overfit 된다고 해석하지 않는다.




Figure 2. 점은 세 seed, 오차 막대는 $\text{mean} \pm \text{std}$ 이다. 점선은 seed-specific ID-Hard reference 의 평균을 나타내며 실제 pass 판정은 seed 별 reference 를 사용한다. Ng16 과 Ng32 를 모두 확인하면 Small 은 기준 아래에 남지만 Medium 은 세 delay 에서 처음으로 기준을 만족한다.

3.2 Partial Fine-Tuning 의 계산 효율

3.1 에서 Medium 이 minimum evaluated sufficient scope 로 확인되었으므로, Full 대신 Medium 을 사용할 때의 실제 비용을 비교하였다.

Scope	Parameters / ratio	Training time	Peak VRAM	Full 대비 감소
Small	373,656 / 3.1625%	125.44 s	161.0 MiB	time 51.47%, VRAM 80.26%
Medium	1,480,728 / 12.5323%	139.80 s	223.7 MiB	time 45.92%, VRAM 72.57%
Full	11,815,320 / 100%	258.48 s	815.7 MiB	기준

Medium 은 Full 대비 trainable parameter 87.47%를 줄이고, measured adaptation training time 45.92%, peak allocated VRAM 72.57%를 줄였다. Small 이 더 저렴하지만 3.1 의 BF criterion 을 만족하지 못했으므로, Medium 은 비용이 가장 작은 scope 가 아니라 성능 기준을 만족한 후보 중 가장 작은 scope 이다.

3.3 OOD severity와 필요한 Fine-Tuning 범위

검증할 가설은 OOD severity가 증가할수록 더 큰 Fine-Tuning scope가 필요할 수 있다는 것이다. Pre-adaptation severity의 seed 별 범위는 다음과 같다.

OOD delay	Pre-Epistemic severity z	상대적 severity	Required scope
160 ns	0.540385~0.568568	낮음	Medium (3/3)
180 ns	0.650400~0.664611	중간	Medium (3/3)
200 ns	0.738193~0.745868	높음	Medium (3/3)

세 delay 사이에서 severity는 160 ns < 180 ns < 200 ns 순서로 증가했다. 그러나 required scope는 모든 조건에서 Medium이었다. 따라서 현재 평가 범위에서는 Epistemic magnitude가 distribution shift의 정도를 반영했지만, 필요한 parameter budget과 단조롭게 연결된다는 근거는 확인되지 않았다. Required scope variation이 없으므로 Spearman correlation은 계산하지 않았고, 이 결과만으로 자동 scope selection policy를 주장하지 않는다.




Figure 3. 위쪽은 seed 별 pre-adaptation z와 평균±표준편차, 아래쪽은 BF-only minimum evaluated scope를 나타낸다. Delay가 증가할수록 severity는 상승하지만 scope는 Medium으로 유지된다는 점을 한 그림에서 확인할 수 있다.

4. 결론

평가한 160~200 ns OOD 환경에서는 전체 predictor를 업데이트하지 않고 12.5323%를 업데이트하는 Medium scope만으로 ID-Hard 수준의 normalized beamforming gain 기준을 만족할 수 있었다. 세 delay와 세 독립 seed의 9개 조건에서 Medium이 모두 minimum evaluated sufficient scope였다.

Medium은 Full보다 trainable parameter 87.47%, measured training time 45.92%, peak allocated VRAM 72.57%를 줄였다. 따라서 현재 조건에서는 Full Fine-Tuning이 아닌 Partial Fine-Tuning으로 비용을 줄일 수 있는 사례를 확인하였다.

Pre-adaptation Epistemic severity는 delay 증가에 따라 높아졌지만 required scope는 모두 Medium이었다. 따라서 uncertainty magnitude만으로 필요한 adaptation budget을 결정하는 관계는 현재 평가 범위에서 확인되지 않았다. 이 결론은 2×2 MIMO, K=1024, 현재 channel simulation, 3-epoch protocol, Small/Medium/Full 후보에 한정된다. Normalized BF gain은 BER/BLER, throughput, 실제 QoS가 아닌 communication-aware surrogate이다. 향후에는 더 다양한 OOD 조건과 세분화된 update scope를 이용해 severity와 adaptation budget의 관계를 추가 검증할 예정이다.

참고문헌

[1] C.-K. Wen, W.-T. Shih, S. Jin, “Deep Learning for Massive MIMO CSI Feedback,” *IEEE Wireless Communications

Letters*, vol. 7, no. 5, pp. 748–751, 2018, doi: 10.1109/LWC.2018.2818160.

[2] A. Amini, W. Schwarting, A. Soleimany, D. Rus, “Deep Evidential Regression,” *Advances in Neural Information Processing Systems 33*, 2020.

[3] Anonymous authors, “UACP: Uncertainty-Aware Channel Prediction in MIMO Networks,” submitted to *ACM MobiHoc ’26*, Tokyo, Japan, 2026. 공개 제출본에 저자·페이지·DOI가 없어 추정하지 않았다.

[4] Y. Ovadia, E. Fertig, J. Ren, Z. Nado, D. Sculley, S. Nowozin, J. V. Dillon, B. Lakshminarayanan, J. Snoek, “Can You Trust Your Model’s Uncertainty? Evaluating Predictive Uncertainty Under Dataset Shift,” *Advances in Neural Information Processing Systems 32*, pp. 13969–13980, 2019.

[5] N. Houlsby, A. Giurghi, S. Jastrzebski, B. Morrone, Q. De Laroussilhe, A. Gesmundo, M. Attarian, S. Gelly, “Parameter-Efficient Transfer Learning for NLP,” *Proceedings of the 36th International Conference on Machine Learning*, PMLR 97, pp. 2790–2799, 2019.

[6] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, “LoRA: Low-Rank Adaptation of Large Language Models,” *International Conference on Learning Representations*, 2022. 본 연구는 LoRA를 구현하지 않았으며 PEFT 배경으로만 인용한다.